

**ANALISIS TINGKAT PENGANGGURAN TERBUKA
DI SUMATERA UTARA TAHUN 2022 MENGGUNAKAN
*SPATIAL AUTOREGRESSIVE (SAR)***



Disusun Oleh:

Daniella Putri Shalomita	2106631072
Diki Wahyudi	2106709131
Raqi Akbar Robbani	2106652562

**DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS INDONESIA**

2024

ABSTRAK

Pengangguran masih menjadi salah satu tantangan yang harus dihadapi dalam pembangunan ekonomi regional. Penelitian ini bertujuan untuk menganalisis tingkat pengangguran terbuka di Sumatera Utara tahun 2022 menggunakan pendekatan *Spatial Autoregressive* (SAR) dengan pembobotan *queen contiguity*. Metode SAR memungkinkan untuk memahami adanya pengaruh lag spasial pada variabel dependen. Hasil analisis menunjukkan bahwa hanya variabel persentase penduduk miskin (PPM) dan *dependency ratio* yang berpengaruh signifikan terhadap tingkat pengangguran terbuka (TPT) di Sumatera Utara tahun 2022.

Kata kunci: Pengangguran, *Spatial Autoregressive*, SAR, Spasial

DAFTAR ISI

ABSTRAK.....	2
DAFTAR ISI.....	3
BAB I	
PENDAHULUAN.....	5
1.1 Latar Belakang.....	5
1.2 Rumusan Masalah.....	6
1.3 Tujuan Penelitian.....	6
BAB II	
TINJAUAN PUSTAKA.....	7
2.1 Regresi Linier Berganda.....	7
2.1.1. Uji Multikolinieritas.....	8
2.1.2. Uji Normalitas.....	8
2.1.3. Uji Heteroskedastisitas.....	9
2.3 Geographically Weighted Regression.....	10
2.3.1 Pendugaan Parameter Model Geographically Weighted Regression.....	11
2.3.2 Pembobot Spasial.....	11
2.3.3 Uji Parameter Model.....	13
2.3.4 Pengukuran Kualitas Model.....	13
BAB III	
METODE PENELITIAN.....	13
3.1. Data penelitian.....	14
3.2. Jenis Data.....	14
3.3. Variabel Penelitian yang Digunakan.....	14
3.4. Metode Analisis.....	15
BAB IV	
HASIL DAN PEMBAHASAN.....	16
4.1 Visualisasi Variabel Penelitian.....	16
4.2 Analisis Regresi Global.....	16
4.3 Uji Multikolinearitas.....	18
4.4 Uji Asumsi Normalitas.....	19
4.5 Uji Asumsi Heterogenitas Spasial.....	20
4.6 Geographically Weighted Regression (GWR).....	21
4.6.1. Pemilihan Bandwidth Optimum.....	21
4.6.2. Pemilihan Model Terbaik.....	22
4.7 Interpretasi Hasil Estimasi.....	23
4.7.1. Sebaran Kelompok Variabel Signifikan.....	23
4.7.2. Keragaman Spasial Taksiran 1.....	25
4.7.3. Keragaman Spasial Taksiran 2.....	26
4.7.4. Keragaman Spasial Taksiran 3.....	27
4.7.5. Keragaman Spasial Taksiran 4.....	28

4.7.6. Perbandingan Residual Regresi Global dan Regresi Lokal.....	29
BAB IV	
KESIMPULAN.....	31
DAFTAR PUSTAKA.....	32
LAMPIRAN CODE.....	34
LAMPIRAN DATA.....	40
KONTRIBUSI KELOMPOK.....	41

BAB I

PENDAHULUAN

1.1 Latar Belakang

Sebagai negara berkembang, Indonesia masih memiliki berbagai permasalahan, salah satunya adalah kemiskinan. Kemiskinan merupakan masalah kompleks yang dipengaruhi oleh berbagai faktor yang saling berkaitan. Menurut I Komang, tingkat pengangguran terbuka dapat menjadi salah satu faktor yang berkaitan erat dengan kemiskinan. Di Indonesia, tingkat pengangguran terbuka menjadi perhatian utama pemerintah dalam upaya mencapai pertumbuhan ekonomi yang inklusif dan berkelanjutan. Salah satunya adalah Provinsi Sumatera Utara yang berkontribusi signifikan terhadap ekonomi nasional, tidak terkecuali dari tantangan tingkat pengangguran.

Terlebih lagi, tahun 2022 dunia dihadapkan pada berbagai tantangan, termasuk pandemi Covid-19 yang sangat berdampak terhadap perekonomian, tak terkecuali Indonesia. Pandemi Covid-19 telah menyebabkan penurunan aktivitas ekonomi, salah satunya yang sangat terasa adalah pengurangan lapangan pekerjaan. Pengurangan lapangan pekerjaan ini tentunya akan meningkatkan angka pengangguran karena ketidakseimbangan antara jumlah lapangan pekerjaan dengan bertambahnya angkatan kerja.

Dalam penelitian ini, penggunaan metode analisis regresi spasial dengan pendekatan area dinilai dapat memodelkan kasus tingkat pengangguran terbuka di daerah Sumatera Utara karena metode ini memungkinkan untuk memahami ketergantungan (dependensi) spasial dalam data dan mengidentifikasi pola-pola lokal yang tidak terdeteksi dalam analisis regresi linier berganda. Dengan menerapkan metode analisis regresi spasial, diharapkan nantinya dapat diidentifikasi faktor-faktor spesifik yang berkaitan dengan tingkat pengangguran terbuka di Sumatera Utara yang berbeda-beda di setiap wilayahnya.

1.2 Rumusan Masalah

Rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Apa model terbaik untuk memodelkan kasus tingkat pengangguran terbuka di Sumatera Utara pada tahun 2022?
2. Bagaimana hasil pemodelan regresi spasial pada kasus tingkat pengangguran terbuka di Sumatera Utara pada tahun 2022?
3. Apa saja faktor-faktor yang signifikan berpengaruh pada tingkat pengangguran terbuka di Sumatera Utara pada tahun 2022?

1.3 Tujuan Penelitian

Tujuan dari penelitian ini adalah sebagai berikut:

1. Untuk mengetahui model terbaik untuk memodelkan kasus pengangguran terbuka di Sumatera Utara pada tahun 2022.
2. Untuk mengetahui hasil pemodelan regresi spasial pada kasus tingkat pengangguran terbuka di Sumatera Utara pada tahun 2022.
3. Untuk mengetahui faktor-faktor yang signifikan berpengaruh pada tingkat pengangguran terbuka di Sumatera Utara pada tahun 2022.

BAB II

TINJAUAN PUSTAKA

2.1 Regresi Linier Berganda

Regresi linier berganda adalah model yang menunjukkan hubungan antara dua atau lebih variabel independen (X) dengan satu variabel dependen (Y). Uji regresi linier berganda bertujuan untuk menentukan nilai-nilai koefisien β yang memberikan estimasi terbaik untuk variabel dependen Y berdasarkan variabel-variabel independen yang diberikan. Selain itu juga dapat mengetahui arah hubungan variabel dependen dengan variabel-variabel independennya.

Secara sistematis, persamaan untuk n observasi dengan variabel independen sebanyak k adalah sebagai berikut.

$$Y_i = \beta_0 + \beta_1 X_{1k} + \beta_2 X_{2k} + \dots + \beta_k X_{ik} + \varepsilon_i; \quad i = 1, 2, \dots, n \quad (2.1)$$

dengan:

- Y_i : nilai observasi variabel dependen ke- i
- β_0 : nilai *intercept* model regresi
- β_k : koefisien regresi variabel independen ke- k
- X_{ik} : nilai observasi variabel independen ke- k pada pengamatan ke- i
- ε_i : *error* pada pengamatan ke- i

- Hipotesis untuk uji simultan (uji F) adalah sebagai berikut:
 - $H_0 : \beta = 0$ (variabel X tidak berpengaruh signifikan)
 - $H_1 : \beta \neq 0$ (setidaknya terdapat satu variabel yang berpengaruh)
 - Hipotesis untuk uji parsial (uji t) adalah sebagai berikut:
 - $H_0 : \beta_i = 0$ (variabel X tidak berpengaruh signifikan)
 - $H_1 : \beta_i \neq 0$ (setidaknya terdapat satu variabel yang berpengaruh)
- dengan $i = 0, 1, 2, \dots, n$*

Dalam melakukan pemodelan regresi, terdapat beberapa asumsi yang harus dipenuhi diantaranya uji multikolinieritas dan uji asumsi residual yaitu uji normalitas, uji homoskedastisitas, dan uji autokorelasi.

2.2.1. Uji Multikolinieritas

Uji multikolinieritas ditujukan untuk menguji adanya hubungan linier antara beberapa variabel independen dalam suatu model regresi linier berganda. Model regresi yang baik adalah model yang variabel independennya tidak memiliki korelasi. Uji ini menggunakan nilai *Tolerance* (TOL) dan *Variance Inflation Factor* (VIF). Apabila nilai TOL < 0.1 atau nilai VIF > 10, maka terdapat masalah multikolinieritas. Nilai TOL dan VIF adalah sebagai berikut.[3]

$$VIF = \frac{1}{R^2_{yj1}} \quad (2.2)$$

$$TOL = \frac{1}{VIF} = (1 - R^2_{yj1}) \quad (2.3)$$

$$\text{dengan } R^2_{yj1} = \frac{r^2_{yj} + r^2_{y1} + 2r_{yj}r_{y1}r_{j1}}{1 - r^2_{j1}} \quad (2.4)$$

2.2.2. Uji Normalitas

Uji normalitas digunakan untuk menguji apakah residual terdistribusi secara normal atau tidak. Uji normalitas dapat dilakukan dengan uji *Jarque-Berra*, *Anderson Darling*, *Kolmogorov-Smirnov*, dan *Skewness-Kurtosis*. Berikut merupakan uji normalitas dengan *Kolmogorov-Smirnov*:

- Hipotesis

H_0 : Residual berdistribusi normal

H_1 : Residual tidak berdistribusi normal

- Tingkat Signifikansi

$\alpha = 0,05$

- Statistik Uji *Kolmogorov-Smirnov*

$$D = \max |F_0 - S_n(x_i)|, i = 1, 2, \dots, N$$

dengan:

$F_0(x)$ = fungsi distribusi kumulatif yang ditentukan

$S_n(x)$ = frekuensi kumulatif yang diobservasi dari sampel acak dengan N observasi

- Daerah Kritis

Tolak H_0 jika $D_{hitung} > D_{tabel}$ atau $p\text{-value} < \alpha$

2.2.3. Uji Heteroskedastisitas

Uji heteroskedastisitas yang dilakukan bertujuan untuk menguji apakah dalam model regresi tersebut memiliki varian yang konstan dari residual atau error antara satu pengamatan ke pengamatan yang lain. Apabila terjadi heteroskedastisitas dalam model regresi, maka estimator yang diperoleh tidak efisien. Terdapat beberapa uji dalam mendeteksi heteroskedastisitas, yaitu uji *Park* dan uji *Breusch Pagan Godfrey*. [7]. Langkah-langkah dalam melakukan uji *Breusch Pagan Godfrey* adalah sebagai berikut.

- Lakukan regresi OLS persamaan

$$Y_i = \beta_0 + \beta_1 X_{1k} + \beta_2 X_{2k} + \dots + \beta_k X_{ik} + \varepsilon_i \text{ sehingga didapat nilai}$$

$$\text{residualnya dan mencari } \sigma^2 = \frac{\sum \hat{e}_i^2}{n} \quad (2.5)$$

- Mencari p_i yang didefinisikan sebagai: $p_i = \frac{\hat{e}_i^2}{\sigma^2} \quad (2.6)$

- Regresi p_i terhadap variabel Z sebagai berikut: $p_i = \alpha_0 + \alpha_1 Z_i = v_i$

- Dapatkan ESS (*explained sum of square*) dan kemudian dapatkan

$$\phi = \frac{1}{2} (ESS). \text{ Jika residual berdistribusi normal, maka akan}$$

mengikuti distribusi Chi-Square (χ^2) sebagai berikut:

$$\phi = \frac{1}{2} (ESS) \approx \chi_{df}^2$$

2.2 Regresi Spasial

Regresi Spasial adalah regresi yang untuk jenis data yang memiliki efek spasial. Efek spasial memiliki arti bahwa letak lokasi antara tiap observasi memiliki pengaruh terhadap nilai pengamatannya. Efek spasial terdiri dari dua macam yaitu dependensi spasial dan heterogenitas spasial (Yasin, 2020).

Bentuk umum model regresi spasial adalah sebagai berikut.

$$y = \rho W y + X\beta + u \quad (2.7)$$

$$u = \lambda W u + \varepsilon, \varepsilon \sim N(0, \sigma_\varepsilon^2 I_n) \quad (2.8)$$

Keterangan:

y	: Vektor variabel dependen yang berukuran $n \times 1$
ρ	: Koefisien parameter spasial lag dari variabel dependen
W	: Matriks pembobot spasial $n \times n$
X	: Matriks variabel independen berukuran $n \times (p+1)$
β	: Vektor koefisien regresi berukuran $(p+1) \times 1$
λ	: Koefisien parameter spasial error
u	: Vektor error yang mempunyai efek spasial, berukuran $n \times 1$
ε	: Vektor error berukuran $n \times 1$

Terdapat beberapa variasi dari regresi spasial tersebut berdasarkan ada atau tidaknya efek spasial pada variabel dependen atau pada error.

1. Spatial Autoregressive Model (SAR)

Ini terjadi jika $\rho \neq 0$ dan $\lambda = 0$, dengan persamaan berikut.

$$y = \rho W y + X\beta + \varepsilon \quad (2.9)$$

2. Spatial Error Model (SEM)

Ini terjadi jika $\rho = 0$ dan $\lambda \neq 0$, dengan persamaan berikut.

$$y = X\beta + u \quad (2.10)$$

$$u = \lambda W u + \varepsilon \quad (2.11)$$

3. Spatial Autoregressive Moving Average (SARMA)

Ini terjadi jika $\rho \neq 0$ dan $\lambda \neq 0$, dengan persamaan berikut.

$$y = \rho W y + X\beta + u \quad (2.12)$$

$$u = \lambda W u + \varepsilon \quad (2.13)$$

2.2.1. Uji Moran's I

Untuk mengetahui keberadaan efek spasial atau dependensi spasial, salah satunya dapat diukur dengan menguji autokorelasi spasial pada residual dari mode linier berganda (Yulianti, 2020). Hipotesis yang digunakan adalah.

$H_0: I = 0$ (tidak ada autokorelasi spasial antar lokasi)

$H_1: I \neq 0$ (ada autokorelasi spasial antar lokasi)

Statistik Uji:

$$I = \frac{\frac{n}{\sum_{i=1}^n \sum_{j=1}^n w_{ij}}}{\frac{\sum_{i=1}^n \sum_{j=1}^n w_{ij} (x_i - \bar{x})(x_j - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}} \quad (2.14)$$

Aturan Keputusan: Tolak H_0 jika $I \neq 0$ atau p-value $< 0,05$.

2.2.2. Uji Lagrange Multiplier

Lagrange Multiplier dapat digunakan untuk menguji dependensi spasial pada variabel dependen dan variabel independen (Fatati, 2017). Hipotesis yang digunakan untuk menguji dependensi spasial adalah sebagai berikut.

a. Lagrange Multiplier Lag

$H_0: \rho = 0$ (tidak ada ketergantungan spasial pada variabel respon)

$H_1: \rho \neq 0$ (ada ketergantungan spasial pada variabel respon)

Statistik Uji:

$$LM_{\rho} = \frac{(e'Wy/(ee'/n))^2}{(D)}, \text{ dengan} \quad (2.15)$$

$$D = \frac{(WX\beta'(I - X(X'X)^{-1}X)(WX\beta))}{\sigma^2} + tr(W'W + WW) \quad (2.16)$$

Aturan Keputusan: H_0 ditolak jika nilai $LM_{\rho} > \chi^2_{\alpha(\rho)}$

b. Lagrange Multiplier Error

$H_0: \lambda = 0$ (tidak ada ketergantungan spasial pada error)

$H_1: \lambda \neq 0$ (ada ketergantungan spasial pada error)

Statistik Uji:

$$LM_{\lambda} = \frac{[e'We/(ee'/n)]^2}{tr(W'W + WW)} \quad (2.17)$$

Aturan Keputusan: H_0 ditolak jika nilai $LM_{\lambda} > \chi^2_{\alpha(\lambda)}$

c. Robust Lagrange Multiplier

Menurut Bera dan Yoon (1993), terdapat modifikasi pada LM pada lag dan LM pada error dengan uji hipotesis dan aturan keputusan yang sama. Berikut adalah statistik uji yang digunakan.

$$RLM_{lag} = \left(\frac{e'Wy}{\sigma^2} - \frac{e'We}{\sigma^2} \right) \left(\frac{1}{\sigma^2} D - T \right)^{-1} \sim \chi^2_{(1)} \quad (2.18)$$

d. Robust Lagrange Error

Modifikasi juga dilakukan pada LM di error. Berikut adalah statistik uji yang digunakan

$$RLM_{SEM} = \left(\frac{e'Me}{\sigma^2} - T\sigma^2 D^{-1} \frac{e'Wy}{\sigma^2} \right)^2 \left(T - T^2 \sigma^2 \frac{1}{D} \right)^{-1} \sim \chi^2_{(1)} \quad (2.19)$$

$$\text{Dimana } D = (WX\beta)'M(WX\beta) + T\sigma^2 \quad (2.20)$$

Hasil yang signifikan untuk kedua uji Lagrange Multiplier Lag dan Lagrange Multiplier Error mengindikasikan bahwa model yang digunakan adalah model SARMA (Sari, Hayati & Wahyuningsih, 2021).

2.3.1 Pendugaan Parameter Model *Spatial Autoregressive Model (SAR)*

SAR atau biasa disebut juga Spatial Lag Model (SLM) adalah model regresi yang hanya memperhitungkan efek spasial pada variabel dependen saja. Estimasi parameter SAR dapat menggunakan persamaan berikut (Djuraidah & Wigena, 2012).

$$\hat{\beta} = (X'X)^{-1}X'y - (X'X)^{-1}\hat{\rho}Wy \quad (2.21)$$

$$\hat{\rho} = (y'W'Wy)^{-1}y'W'y \quad (2.22)$$

2.3.2 Pembobot Spasial

Matriks pembobot spasial merupakan hubungan yang menggambarkan antar wilayah. Matriks pembobot spasial adalah unsur yang sangat penting dalam menggambarkan kedekatan antara suatu lokasi dengan lokasi lain. Matriks pembobot spasial menunjukkan hubungan antara keseluruhan lokasi, maka dimensi dari matriks ini adalah $n \times n$ dimana n merupakan banyaknya lokasi atau banyaknya unit lintas objek. Matriks pembobot spasial digambarkan secara umum dalam bentuk matriks sebagai berikut: (Ningsih, 2018)

$$W = \begin{bmatrix} W_{11} & W_{12} & W_{13} & \cdots & W_{1n} \\ W_{21} & W_{22} & W_{23} & \cdots & W_{2n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ W_{n1} & W_{n2} & W_{n3} & \cdots & W_{nn} \end{bmatrix}$$

Beberapa pendekatan dapat dilakukan untuk menampilkan hubungan spasial antar lokasi diantaranya adalah konsep persinggungan atau *contiguity* dan konsep jarak atau *distance*.

1. *Contiguity Weight*

Terdapat tiga yakni tipe, yaitu *Rook Contiguity* (persinggungan sisi), *Bishop Contiguity* (persinggungan sudut) serta *Queen Contiguity* (persinggungan sisi dan sudut).

- *Rook Contiguity* : persentuhan sisi wilayah satu dengan sisi wilayah yang lain yang bertetanggaan.
 $w_{ij} = 1$ jika lokasi i dan j memiliki *common edge*.
 $w_{ij} = 0$ jika lainnya.
- *Bishop Contiguity* : persentuhan titik vertek wilayah satu dengan wilayah tetangga yang lain
 $w_{ij} = 1$ jika lokasi i dan j memiliki *common vertex*.
 $w_{ij} = 0$ jika lainnya.
- *Queen Contiguity* : persentuhan baik sisi maupun titik vertek wilayah satu dengan wilayah yang lain yaitu gabungan *rook contiguity* dan *bishop contiguity*.
 $w_{ij} = 1$ jika lokasi i dan j memiliki *common edge* dan *common vertex*.
 $w_{ij} = 0$ jika lainnya.

2. *Distance Weight*

Cara lain dalam menentukan entri-entri matriks pembobot adalah menggunakan fungsi jarak. Pada prinsipnya bobot jarak antara suatu lokasi dengan lokasi lain ditentukan dengan jarak kedua daerah itu. Semakin dekat jarak kedua lokasi tersebut maka bobot yang diberikan semakin besar.

- Fungsi jarak menurun

$$w_{ij} = d_{ij}^2 \text{ jika } d \leq D, z < 0$$

$$w_{ij} = 0 \text{ jika } d > D$$

- K-Lokasi

Pada cara ini peneliti menentukan sebanyak k lokasi j di sekitar lokasi i yang terdekat dengan lokasi tersebut.

- Invers jarak

$$W_{ij} = \frac{1}{d_{ij}} \text{ jika } d \leq D$$

$$W_{ij} = 0 \text{ jika } d > D$$

2.3.3 Uji Parameter Model

Model yang telah dibangun akan diuji parameternya yang dapat dilakukan secara multivariat atau univariat.

- a. Uji Parsial

$$H_0: \beta_k(u_i, v_i) = 0$$

$$H_1: \text{Setidaknya satu } \beta_p(u_i, v_i) \neq 0$$

- b. Uji Serentak

$$H_0: \beta_k(u_i, v_i) = 0$$

$$H_1: \beta_k(u_i, v_i) \neq 0$$

2.3.4 Pengukuran Kualitas Model

Pada penelitian ini hanya digunakan satu metode untuk menentukan model yang terbaik, yaitu AIC (*Akaike Information Criterion*). AIC adalah ukuran relatif kebaikan fit dari model statistik secara umum dengan memperkirakan kualitas masing-masing model, relatif terhadap masing-masing model potensial lainnya. Nilai AIC yang lebih kecil mengartikan bahwa model tersebut lebih baik. Berikut cara menentukan nilai AIC.

$$AIC = 2p - 2 \ln(L), \quad (2.18)$$

dimana $L = L(\hat{\theta})$ (nilai maksimum fungsi likelihood).

BAB III

METODE PENELITIAN

3.1. Data penelitian

Data penelitian yang digunakan merupakan data sekunder dari website Badan Pusat Statistik (BPS) Provinsi Sumatera Utara.

3.2. Jenis Data

Jenis data yang digunakan merupakan data spasial yang memiliki variabel koordinat.

3.3. Variabel Penelitian yang Digunakan

Dalam melakukan penelitian terkait analisis Tingkat Pengangguran Terbuka (TPT) di Sumatera Utara tahun 2022, variabel-variabel yang digunakan tertera pada Tabel 1 sebagai berikut.

Tabel 3.1. Variabel Penelitian

No.	Kategori	Variabel	Jenis Variabel	Penjelasan Variabel
1	Variabel Independen	Persentase Penduduk Miskin (PPM); X_1	Numerik	Persentase penduduk yang berada dibawah Garis Kemiskinan (GK).
2		<i>Dependency Ratio</i> (DR); X_2	Numerik	Angka yang menyatakan perbandingan antara banyaknya penduduk usia nonproduktif (penduduk di bawah 15 tahun dan penduduk diatas 65 tahun) dengan banyaknya penduduk usia produktif (penduduk usia 15–64 tahun).
3		Gini Rasio (GR); X_3	Numerik	Alat mengukur derajat ketidakmerataan distribusi penduduk; dimana jika $<0,4$ maka tingkat ketimpangan rendah; jika $0,4-0,5$, maka tingkat ketimpangan sedang; jika $>0,5$, maka tingkat ketimpangan tinggi.

4		Rata-Rata Lama Sekolah (RRLS); X_4	Numerik	Jumlah tahun belajar penduduk usia 15 tahun keatas yang telah diselesaikan dalam pendidikan formal (tidak termasuk tahun yang mengulang)
5	Variabel Dependen	Tingkat Pengangguran Terbuka (TPK); Y	Numerik	Tingkat pengangguran terbuka adalah persentase jumlah pengangguran terhadap jumlah angkatan kerja

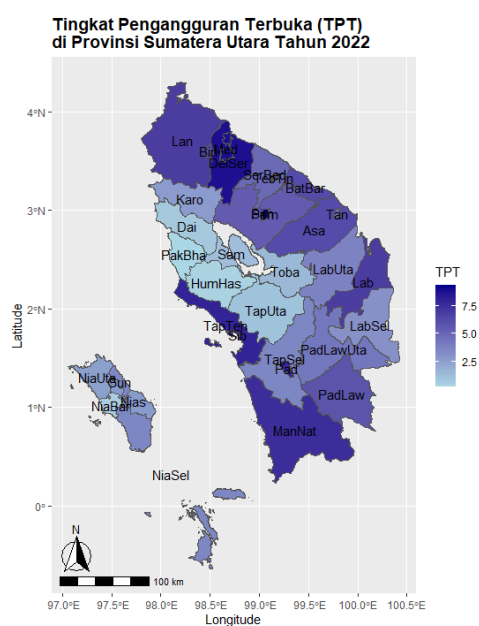
3.4. Metode Analisis

Dalam penelitian ini, analisis dilakukan dengan menggunakan *Spatial Autoregressive* (SAR).

HASIL DAN PEMBAHASAN

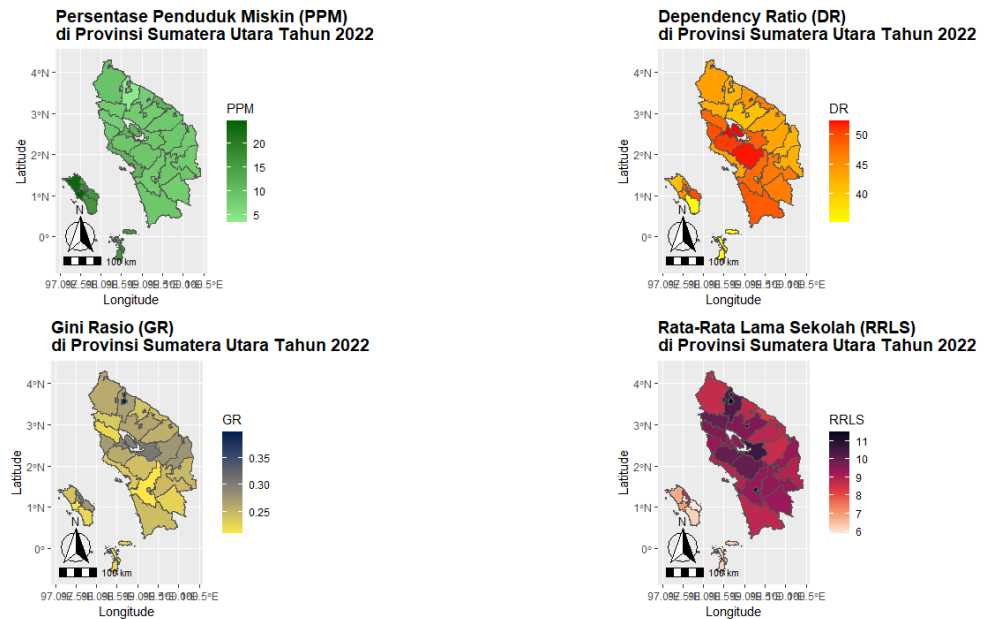
4.1 Visualisasi Variabel Penelitian

Tingkat pengangguran kabupaten/kota di setiap kabupaten/kota beragam dari yang terendah di Kabupaten Pakpak Bharat sebesar 0.26 sampai tertinggi di Kabupaten Pematangsiantar sebesar 9.36. Data sebaran tingkat pengangguran terbuka di Sumatera Utara tahun 2022 dipetakan pada Gambar 4.1.



Gambar 4.1 Peta Tingkat Pengangguran Terbuka Tahun 2022 di Sumatera Utara

Berdasarkan gambar di atas, terlihat bahwa terdapat pola mengelompok pada tingkat pengangguran terbuka yang rendah di Sumatera Utara.



Gambar 4.2 Peta Variabel Independen

Gambar 4.2 merupakan grafik peta dari variabel independen yang digunakan, yaitu persentase penduduk miskin (PPM), *dependency ratio* (DR), gini rasio (GR), dan rata-rata lama sekolah (RRLS). Variabel persentase penduduk miskin pada peta cenderung memiliki kluster berdasarkan wilayah, terlihat dari daerah yang berbeda pulau (bagian barat bawah pulau) tingkat PPM-nya cenderung lebih tinggi daripada yang lainnya. Sedangkan pada variabel rata-rata lama sekolah, daerah yang berada di pulau yang lebih besar (bagian timur atas pulau) memiliki tingkat RRLS yang lebih tinggi dibandingkan daerah pada pulau yang terpisah (bagian barat bawah pulau).

4.2 Statistika Deskriptif

Tabel 4.1 Statistika Deskriptif dari Data

Variabel	Minimum	Mean	Median	Maksimum
TPT	0.260	4.651	4.620	9.360
PPM	3.62	10.32	8.89	24.75
DR	35.18	44.86	43.65	52.46
GR	0.2090	0.2665	0.2580	0.3990
RRLS	5.880	9.287	9.400	11.500


Tabel 4.1 merupakan rangkuman statistika deskriptif dari variabel yang digunakan dalam penelitian. Terlihat bahwa variabel *dependency ratio* memiliki rentang nilai yang tinggi.

4.3 Analisis Regresi Linier

Pemodelan regresi global ini bertujuan untuk melakukan analisis awal pada data tingkat pengangguran terbuka. Pendugaan parameter model regresi global dilakukan dengan metode *Ordinary Least Square* (OLS). Berikut ini merupakan model regresi yang digunakan untuk data ini.

$$\ln(Y_i) = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + \beta_4 X_{4i} + \varepsilon_i \quad (4.1)$$

Dalam persamaan di atas, dilakukan transformasi logaritma natural pada variabel Y untuk menyesuaikan dengan tujuan dari penelitian ini, yaitu melakukan pemodelan regresi spasial. Berikut ini plot perbandingan densitas variabel Y sebelum dan sesudah dilakukan transformasi.



Gambar 4.3 Perbandingan Densitas Variabel Y Sebelum dan Sesudah Transformasi Logaritma Natural

Terlihat bahwa setelah transformasi, densitas variabel Y menjadi memiliki puncak dibandingkan sebelum transformasi. Kedua densitas tersebut tidak terlalu mirip dengan distribusi normal.

Tabel 4.2 Pendugaan Parameter dengan Metode OLS

Variabel	Koefisien	Nilai t	Std. Error	$p - value$
<i>Intercept</i>	9.04016	2.31498	3.905	0.000542
X_1 (PPM)	-0.10277	0.04489	-2.289	0.02981
X_2 (DR)	-0.13835	0.0335	-4.13	0.000297
X_3 (GR)	4.53982	3.96284	1.146	0.261659
X_4 (RRLS)	-0.18775	0.17091	-1.099	0.281321

Tabel 4.2 adalah ringkasan hasil pendugaan parameter dari model regresi global. Dari tabel tersebut, taksiran model regresi global untuk data ini adalah:

$$\ln(Y_i) = 9.04016 - 0.10277X_{1i} - 0.13835X_{2i} + 4.53982X_{3i} - 0.18775X_{4i} \quad (4.2)$$

Hasil uji global F didapatkan bahwa nilai $F = 6.514$ dan $p - value = 0.0007755 < \alpha = 0.05$. Dari hasil tersebut, didapatkan bahwa H_0 ditolak karena $p - value < \alpha$. Berarti, setidaknya terdapat satu variabel independen yang memberikan pengaruh signifikan terhadap variabel dependen.

Berdasarkan tabel 4.2, menggunakan uji parsial t , didapatkan bahwa variabel X_3 (Gini Rasio) dan X_4 (Rata-Rata Lama Sekolah) tidak memberikan pengaruh signifikan terhadap variabel dependen (Tingkat Pengangguran Terbuka) pada tingkat signifikansi 5%. Nilai AIC model yang diperoleh adalah sebesar 79.15504. Koefisien determinasi (R^2) model adalah 0.482. Berarti, hanya 48.2% variabilitas dari variabel dependen yang dapat dijelaskan oleh variabel independen pada model (4.2).

4.4 Uji Multikolinearitas

Pengujian asumsi multikolinieritas dapat dilihat berdasarkan nilai *Variance Inflation Factor* (VIF). Multikolinearitas terjadi saat VIF bernilai lebih dari 10. Berikut merupakan nilai VIF setiap variabel independen.

```
> vif(reg)
PPM_2022    DR_2022    GR_2022  RRLS_2022
2.422487    1.051194    1.655572    3.303844
```

Gambar 4.4 Output VIF Model Regresi

Berdasarkan *output* di atas, tidak ada nilai VIF yang lebih dari 10. Jadi, tidak ada masalah multikolinieritas pada model ini.

4.5 Uji Asumsi Normalitas

- Hipotesis:
 H_0 : Residual Mengikuti Distribusi Normal
 H_1 : Residual Tidak Mengikuti Distribusi Normal
- Tingkat Signifikansi:
 $\alpha = 0.05$
- Statistik Uji:

```
> shapiro.test(reg$residuals)

      shapiro-wilk normality test

data:  reg$residuals
W = 0.9519, p-value = 0.1512

> ks.test(reg$residuals, "pnorm")

      Exact one-sample kolmogorov-smirnov test

data:  reg$residuals
D = 0.16135, p-value = 0.3213
alternative hypothesis: two-sided
```

Gambar 4.5 Output Uji Kolmogorov-Smirnov 1 Sampel dan Uji Shapiro-Wilk

- Aturan Keputusan dan Kesimpulan:
Tolak H_0 jika $p - value < \alpha$. Karena kedua uji memberikan hasil $p - value > 0.05$, maka kedua uji menghasilkan hasil yang sama yaitu H_0 diterima. Jadi, residual model regresi mengikuti distribusi normal.

4.6 Uji Asumsi Autokorelasi

- Hipotesis:
 H_0 : Tidak terjadi autokorelasi pada residual
 H_1 : Terjadi autokorelasi pada residual
- Tingkat Signifikansi:
 $\alpha = 0.05$
- Statistik Uji:

```
> dwtest(log(TPT_2022) ~ PPM_2022 + DR_2022 + GR_2022 + RRLS_2022, data = df)

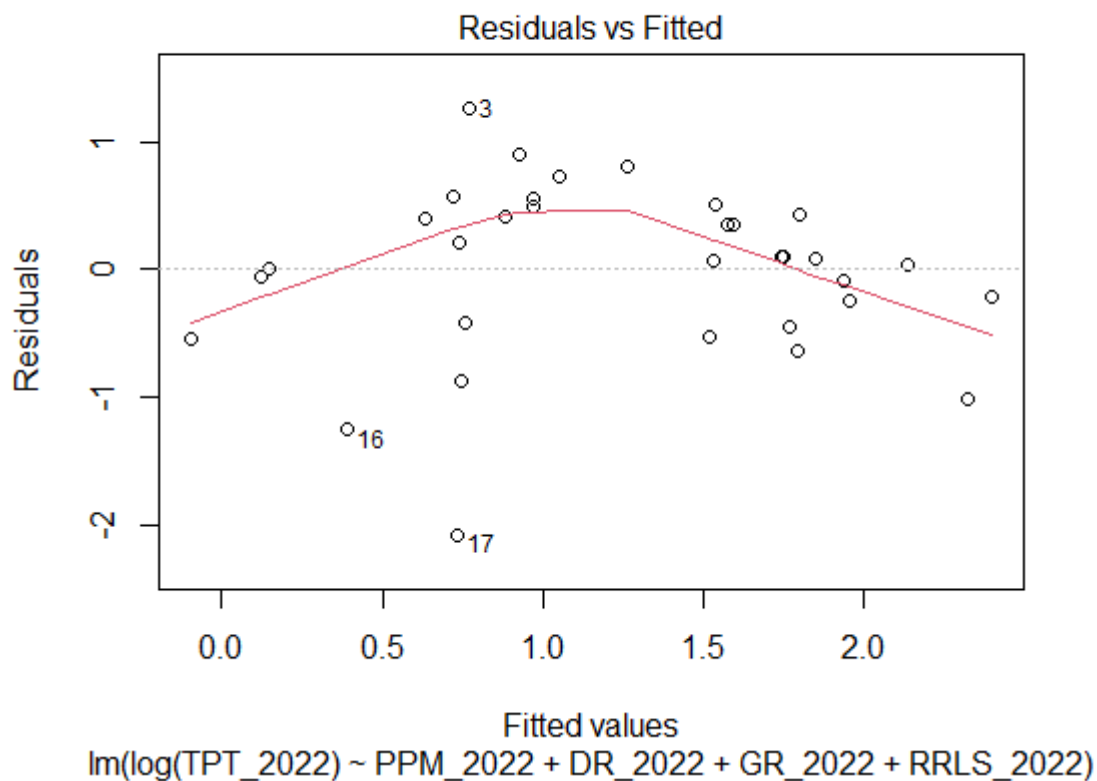
Durbin-Watson test

data:  log(TPT_2022) ~ PPM_2022 + DR_2022 + GR_2022 + RRLS_2022
DW = 2.0246, p-value = 0.5269
alternative hypothesis: true autocorrelation is greater than 0
```

Gambar 4.6 Output Uji Durbin-Watson

- Aturan Keputusan dan Kesimpulan:
Tolak H_0 jika $p - value < \alpha$. Karena uji Durbin-Watson memberikan hasil $p - value = 0.5269 > 0.05$, maka H_0 diterima. Jadi, tidak ada masalah autokorelasi pada residual model regresi.

4.7 Uji Asumsi Homoskedastisitas



Gambar 4.7 Plot Residual Dibandingkan dengan Taksiran Nilai Y

Dari gambar 4.7, secara subjektif, terlihat bahwa pola pada plot merupakan pola titik-titik yang *random*. Namun, perlu dilakukan pengujian hipotesis agar terjamin kevalidan informasinya. Oleh karena itu, dilakukan uji homoskedastisitas dengan menggunakan uji Breusch-Pagan untuk mendeteksi adanya heterogenitas.

- Hipotesis:

H_0 : Tidak terdapat heterogenitas

H_1 : Terdapat heterogenitas

- Tingkat Signifikansi:

$$\alpha = 0.05$$

- Statistik Uji:

```
> bptest(reg)

studentized Breusch-Pagan test

data:  reg
BP = 3.8957, df = 4, p-value = 0.4203
```

Gambar 4.8 Output Uji Breusch-Pagan

- Aturan Keputusan dan Kesimpulan:

Tolak H_0 jika $p - value < \alpha$. Karena uji memberikan hasil

$p - value = 0.4203 > \alpha = 0.05$, maka H_0 tidak ditolak. Jadi, tidak terdapat masalah heterogenitas pada model regresi.

4.8 Model Regresi Spasial

4.8.1 Uji Indeks Moran Variabel Dependen

Uji Indeks Moran adalah uji statistik yang digunakan untuk mendeteksi apakah terdapat autokorelasi spasial atau tidak. Nilai Indeks Moran berada pada rentang antara -1 dan 1 (-1 menunjukkan autokorelasi spasial negatif sempurna dan 1 menunjukkan autokorelasi spasial positif sempurna). Matriks pembobot spasial digunakan untuk membuat daftar tetangga berdasarkan wilayah dengan batas yang berdekatan, yaitu berbagi satu atau lebih titik batas. Matriks pembobot spasial yang digunakan adalah matriks pembobot spasial Queen, dengan kriteria kondisi kedekatannya yaitu satu titik batas bersama.

- Hipotesis:

$H_0: I = 0$ (tidak ada dependensi spasial)

$H_1: I \neq 0$ (terdapat dependensi spasial)

- Tingkat Signifikansi:

$$\alpha = 0.05$$

- Statistik Uji:

```

> moran.test(log(df_merge_sp$TPT_2022), rwm, alternative = "two.sided")

Moran I test under randomisation

data: log(df_merge_sp$TPT_2022)
weights: rwm

Moran I statistic standard deviate = 3.6911, p-value = 0.0002233
alternative hypothesis: two.sided
sample estimates:
Moran I statistic      Expectation      Variance
      0.47110191      -0.03125000      0.01852289

```

Gambar 4.9 Uji Dependensi Spasial Variabel TPT

- Aturan Keputusan dan Kesimpulan:
 H_0 ditolak jika $p - value < \alpha$. Karena $p - value = 0.0002233 < \alpha = 0.05$, maka H_0 ditolak. Jadi, dapat disimpulkan bahwa terdapat dependensi spasial pada variabel dependen sehingga data dapat dimodelkan dengan regresi spasial.

4.8.2 Uji Indeks Moran Variabel Independen

Berikut ini hasil dari uji indeks Moran pada semua variabel independen yang digunakan.

- Hipotesis:
 $H_0: I = 0$ (tidak ada dependensi spasial)
 $H_1: I \neq 0$ (terdapat dependensi spasial)
- Tingkat Signifikansi:
 $\alpha = 0.05$
- Statistik Uji:

Tabel 4.3 Uji Indeks Moran pada Variabel Independen

Variabel	Statistik Uji I	$p - value$
PPM	6.2407	4.355×10^{-10}
DR	1.9718	0.04863
GR	0.33757	0.7357
RRLS	4.1806	2.907×10^{-5}

- Aturan Keputusan dan Kesimpulan:
 H_0 ditolak jika $p - value < \alpha$. Karena hanya variabel gini rasio (GR) yang tidak memenuhi $p - value < \alpha = 0.05$, maka H_0 untuk

variabel gini rasio tidak ditolak. Jadi, dapat disimpulkan bahwa terdapat dependensi spasial pada variabel independen, kecuali pada variabel gini rasio.

4.8.3 Uji Indeks Moran Residual Regresi Linier

Berikut ini merupakan hasil uji indeks Moran pada residual regresi linier.

- Hipotesis:
 $H_0: I = 0$ (tidak ada dependensi spasial)
 $H_1: I \neq 0$ (terdapat dependensi spasial)
- Tingkat Signifikansi:
 $\alpha = 0.05$
- Statistik Uji:

```
> lm.morantest(reg, rwm, alternative = "two.sided")

Global Moran I for regression residuals

data:
model: lm(formula = log(TPT_2022) ~ PPM_2022 + DR_2022 + GR_2022 + RRLS_2022,
data = df)
weights: rwm

Moran I statistic standard deviate = 2.3501, p-value = 0.01877
alternative hypothesis: two.sided
sample estimates:
Observed Moran I      Expectation      Variance
0.24892840      -0.06724457      0.01809946
```

Gambar 4.10 Uji Dependensi Spasial Residual Regresi Linier

- Aturan Keputusan dan Kesimpulan:
 H_0 ditolak jika $p - value < \alpha$. Karena $p - value = 0.01877 < \alpha = 0.05$, maka H_0 ditolak. Jadi, dapat disimpulkan bahwa terdapat dependensi spasial pada variabel residual model regresi linier sehingga data dapat dimodelkan dengan regresi spasial.

4.8.4 Uji Lagrange Multiplier

Berikut ini hasil akan dilakukan uji Lagrange Multiplier untuk mengetahui spesifikasi dependensi spasial yang terjadi pada data.

Tabel 4.4 Uji Indeks Moran pada Variabel Independen

Variabel	Statistik Uji LM	$p - value$	Kesimpulan
Spatial Error Model	2.9023	0.08845	Tidak Signifikan
Spatial Lag Model	5.187	0.02276	Signifikan
Robust Spatial Error Model	0.071589	0.789	Tidak Signifikan
Robust Spatial Lag Model	2.3563	0.1248	Tidak Signifikan
SARMA	5.2586	0.07213	Tidak Signifikan

Terlihat bahwa hanya uji Lagrange Multiplier pada ρ (Spatial Lag Model) yang signifikan. Artinya, berdasarkan uji Lagrange Multiplier, model Spatial Autoregressive (SAR) merupakan model regresi spasial yang cocok untuk data ini.

4.8.5 Perbandingan Model Regresi Spasial

Pemodelan regresi spasial dilakukan dengan membandingkan beberapa model. Model terbaik dipilih berdasarkan skor AIC terkecil. Berikut ini merupakan tabel perbandingan model regresi spasial.

Tabel 4.5 Perbandingan Model Regresi Spasial

Koefisien	OLS	SAR	SEM	SLX
<i>Intercept</i>	9.04016	7.509785	7.329605	19.52
β_1 (PPM)	-0.10277	-0.087618	-0.076170	-0.08365
β_2 (DR)	-0.13835	-0.109238	-0.107272	-0.1292
β_3 (GR)	4.53982	4.012759	5.837550	3.509
β_4 (RRLS)	-0.18775	-0.219237	-0.220365	-0.2853
<i>Lag PPM</i>	-	-	-	-0.06069
<i>Lag DR</i>	-	-	-	-0.1034
<i>Lag GR</i>	-	-	-	-19.34
<i>Lag RRLS</i>	-	-	-	0.03234
ρ	-	0.41377	-	-

λ	-	-	0.48631	-
Normalitas Residual	0.16135 (Terpenuhi)	0.19945 (Terpenuhi)	0.20024 (Terpenuhi)	0.19419 (Terpenuhi)
Homogenitas Residual	3.8957 (Terpenuhi)	3.0506 (Terpenuhi)	1.2869 (Terpenuhi)	6.6417 (Terpenuhi)
Log-Likelihood	-33.57752	-30.47203	-31.35799	-28.50365
AIC	79.15504	74.94406	76.71598	77.00729

Tabel 4.6 Perbandingan Model Regresi Spasial (Lanjutan)

Koefisien	SDM	SDEM	SAC	GNSM
<i>Intercept</i>	14.975157	18.244435	7.455797	10.983003
β_1 (PPM)	-0.073745	-0.081728	-0.086974	-0.059325
β_2 (DR)	-0.121072	-0.128049	-0.108358	-0.107273
β_3 (GR)	3.940852	3.587924	3.891511	4.956324
β_4 (RRLS)	-0.289489	-0.298106	-0.217515	-0.230252
<i>Lag</i> PPM	-0.036105	-0.068706	-	0.043725
<i>Lag</i> DR	-0.056496	-0.088481	-	-0.046356
<i>Lag</i> GR	-16.543434	-15.899405	-	-22.193354
<i>Lag</i> RRLS	0.100839	0.012846	-	0.347166
ρ	0.25029	-	0.43363	0.56235
λ	-	0.15779	-0.038152	-0.51594
Normalitas Residual	0.23778 (Tidak Terpenuhi)	0.22032 (Terpenuhi)	0.19536 (Terpenuhi)	0.25717 (Tidak Terpenuhi)
Homogenitas Residual	6.2481 (Terpenuhi)	5.469 (Terpenuhi)	3.2365 (Terpenuhi)	9.0033 (Terpenuhi)
Log-Likelihood	-27.86487	-28.35119	-30.46549	-27.18366
AIC	77.72974	78.70239	76.93097	78.36732

Keterangan: OLS: Regresi Linier *Ordinary Least-Squares*, SAR: Spatial Autoregressive Model, SEM: Spatial Error Model, SLX: Spatial Lag Exogenous Model, SDM: Spatial Durbin Model, SDEM: Spatial Durbin Error Model, SAC: Spatial Autoregressive Combined, dan GNSM: General Nested Spatial Model.

Berdasarkan Tabel 4.5, didapatkan bahwa model Spatial Autoregressive (SAR) merupakan model terbaik untuk data ini karena memiliki AIC yang paling kecil.

4.8.6 Model Terbaik

Berdasarkan bagian sebelumnya, didapatkan bahwa model Spatial Autoregressive merupakan model terbaik untuk data ini. Berikut ini merupakan *summary* dari model SAR.

```
> summary(sar)

Call:lagsarlm(formula = model, data = df_merge_sp, listw = rwm)

Residuals:
    Min       1Q   Median       3Q      Max
-1.82055 -0.36948  0.11226  0.34308  1.21970

Type: lag
Coefficients: (asymptotic standard errors)
              Estimate Std. Error z value Pr(>|z|)
(Intercept)  7.509785   1.943630  3.8638 0.0001116
PPM_2022    -0.087618   0.036968 -2.3701 0.0177821
DR_2022     -0.109238   0.028463 -3.8378 0.0001241
GR_2022      4.012759   3.246687  1.2360 0.2164752
RRLS_2022   -0.219237   0.139581 -1.5707 0.1162572

Rho: 0.41377, LR test value: 6.211, p-value: 0.012696
Asymptotic standard error: 0.13774
      z-value: 3.004, p-value: 0.0026642
Wald statistic: 9.0242, p-value: 0.0026642

Log likelihood: -30.47203 for lag model
ML residual variance (sigma squared): 0.35178, (sigma: 0.59311)
Number of observations: 33
Number of parameters estimated: 7
AIC: 74.944, (AIC for lm: 79.155)
LM test for residual autocorrelation
test value: 0.013991, p-value: 0.90584
```

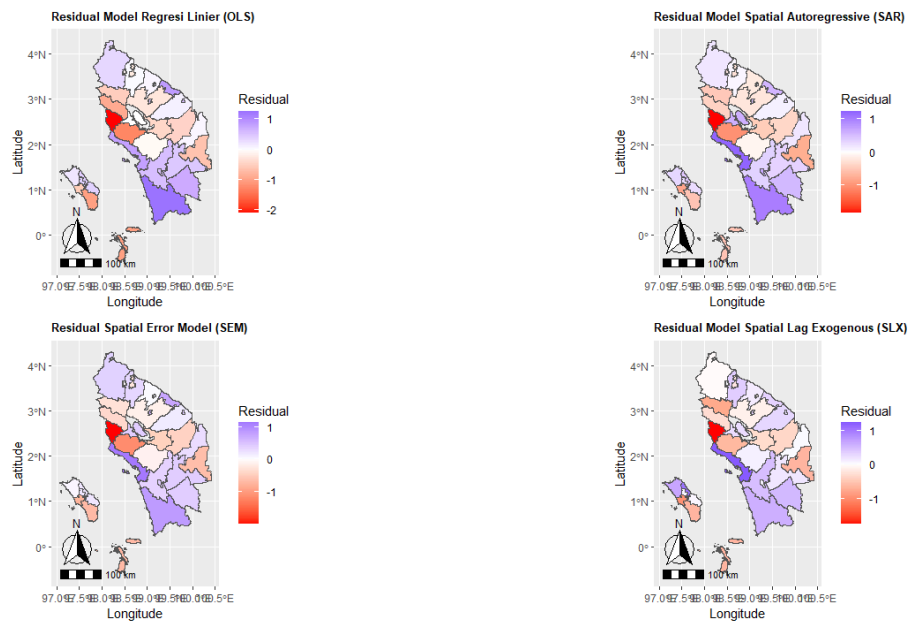
Gambar 4.11 Output Summary Model Spatial Autoregressive (SAR)

Berdasarkan Gambar 4.11, didapatkan dua variabel yang tidak signifikan, yaitu variabel Gini Rasio (GR) dan Rata-Rata Lama Sekolah (RRLS) karena masing-masing p - $value$ koefisiennya tidak memenuhi p - $value < \alpha = 0.05$. Selain itu, terlihat bahwa koefisien ρ model signifikan karena p - $value = 0.012696 < \alpha = 0.05$. Karena koefisien ρ bernilai positif, berarti variabel tingkat pengangguran terbuka antardaerah berhubungan positif dengan daerah di sekitarnya. Model SAR yang sesuai untuk analisis regresi spasial Tingkat Pengangguran Terbuka (TPT) di Sumatera Utara tahun 2022 adalah sebagai berikut.

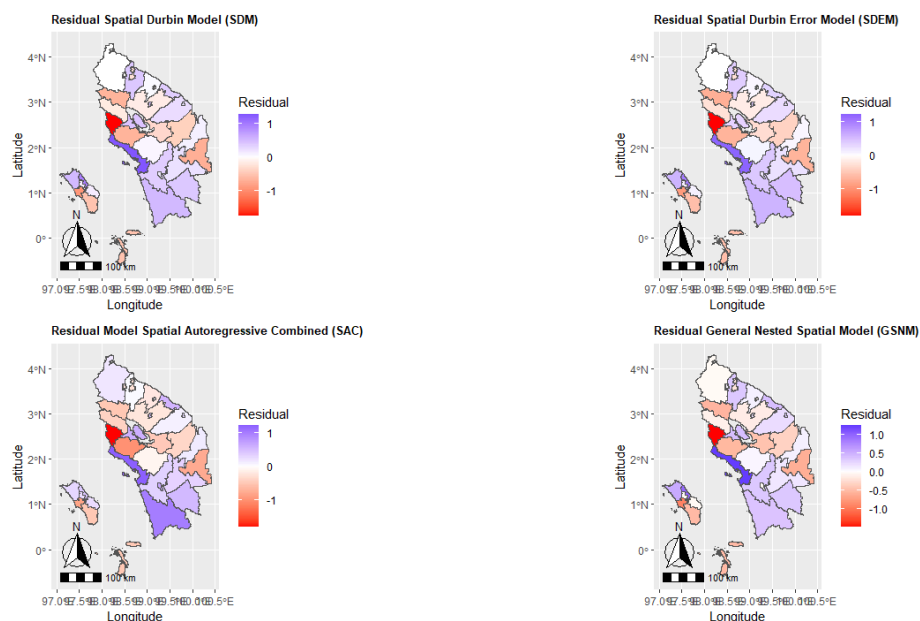
$$\ln(\hat{Y}_i) = 0.41377 \sum_{j=1, j \neq i}^{33} w_{ij} Y_j + 7.509785 - 0.087618X_{1i} - 0.109238X_{2i} + 4.012759X_{3i} - 0.219237X_{4i} \quad (4.3)$$

4.8.7 Perbandingan Residual Regresi Spasial

Berikut ini merupakan peta plot residual dari model-model regresi spasial dan regresi linier.



Gambar 4.12 Peta Residual Model Regresi Linier dan Model-Model Regresi Spasial



Gambar 4.13 Peta Residual Model Regresi Linier dan Model-Model Regresi Spasial (Lanjutan)

Pada Gambar 4.11, terlihat bahwa peta residual regresi linear tidak memiliki warna yang berbeda secara signifikan dibandingkan dengan peta residual model Spatial Autoregressive (SAR), yang merupakan model terbaik untuk data ini. Selain itu, secara umum berdasarkan warna peta residualnya, kedelapan model tidak memiliki perbedaan warna yang signifikan.

BAB IV

KESIMPULAN

Berdasarkan hasil analisis yang telah dilakukan, diperoleh kesimpulan sebagai berikut.

1. Model Spatial Autoregressive (SAR) lebih baik dibandingkan model Regresi Linier dalam penentuan faktor-faktor yang berpengaruh terhadap tingkat pengangguran terbuka di Sumatera Utara tahun 2022 karena terdapat dependensi spasial pada data. Selain itu, AIC model SAR lebih kecil daripada model regresi spasial lainnya sehingga model SAR menjadi model terbaik berdasarkan kriteria AIC.
2. Pada kasus ini, terdapat 2 variabel dari 4 variabel yang diujikan berpengaruh signifikan terhadap tingkat pengangguran terbuka di Sumatera Utara tahun 2022, yaitu persentase penduduk miskin (PPM) dan *dependency ratio* (DR). Selain itu, didapatkan bahwa koefisien ρ signifikan pada model SAR dan bernilai positif yang berarti terdapat hubungan yang positif pada tingkat pengangguran terbuka di Sumatera Utara di satu daerah dengan daerah di sekitarnya.

DAFTAR PUSTAKA

- [1] Adi Putra, I. K. A. (n.d.). Analisis Pengaruh Tingkat Pengangguran Terbuka, Kesempatan Kerja, Dan Tingkat Pendidikan Terhadap Tingkat Kemiskinan Pada Kabupaten/Kota Di Provinsi Bali. *E-Jurnal EP Unud*, 7(3), 416-444.
- [2] BPS Sumatera Utara. (2023). *Gini Ratio Sumatera Utara Menurut Kabupaten/Kota 2021-2023*.
<https://sumut.bps.go.id/indicator/23/467/1/gini-ratio-sumatera-utara-menurut-kabupaten-kota.html>
- [3] BPS Sumatera Utara. (2023). *Penduduk, Laju Pertumbuhan Penduduk, Distribusi Persentase Penduduk, Kepadatan Penduduk, Rasio Jenis Kelamin Penduduk Menurut Kabupaten/Kota, 2020 dan 2022*.
<https://sumut.bps.go.id/statictable/2023/03/10/2927/penduduk-laju-pertumbuhan-penduduk-distribusi-persentase-penduduk-kepadatan-penduduk-rasio-jenis-kelamin-penduduk-menurut-kabupaten-kota-2020-dan-2022.html>
- [4] BPS Sumatera Utara. (2023). *Penduduk, Laju Pertumbuhan Penduduk, Distribusi Persentase Penduduk, Kepadatan Penduduk, Rasio Jenis Kelamin Penduduk Menurut Kabupaten/Kota, 2020 dan 2022*.
<https://sumut.bps.go.id/statictable/2023/03/10/2927/penduduk-laju-pertumbuhan-penduduk-distribusi-persentase-penduduk-kepadatan-penduduk-rasio-jenis-kelamin-penduduk-menurut-kabupaten-kota-2020-dan-2022.html>
- [5] BPS Sumatera Utara. (2023). *Rata-Rata Lama Sekolah Tahun (2021-2023)*.
<https://sumut.bps.go.id/indicator/26/77/1/rata-rata-lama-sekolah.html>
- [6] BPS Sumatera Utara. (2023). *Tingkat Pengangguran Terbuka (TPT) Penduduk Umur 15 Tahun Keatas Menurut Kab/Kota (Persen), 2021-2023*.
<https://sumut.bps.go.id/indicator/6/44/1/tingkat-pengangguran-terbuka-tpt-penduduk-umur-15-tahun-keatas-manurut-kab-kota.html>
- [7] Ghozali, I. (2016). *Aplikasi Analisis Multivariate Dengan Program IBM SPSS 23* (Edisi 8). Cetakan ke VIII. Badan Penerbit Universitas Diponegoro.
- [8] Open Data Sumatera Utara. (2022). *Rasio Ketergantungan (Dependency Ratio) Menurut Kabupaten/Kota Di Provinsi Sumatera Utara, 2022*.
<https://sadaina.sumutprov.go.id/open-data/dataset/2d92576a-126d-51c1-a8bb-5a8bd9c7b8e8>

- [9] Suryono. (2015). *Analisis Regresi untuk Penelitian* (1st ed. ed., Vol. Vol.1). Deepublish.
- [10] Uthami, I. A. (2013). Regresi Kuantil Median untuk Mengatasi Heteroskedastisitas pada Analisis Regresi. *e-Jurnal Matematika*, 2(1), 6-13.
- [11] Yulianti, S. (2020). *Pemodelan Data Panel Spasial Pada Indeks Pembangunan Manusia Di Jawa Tengah*. Universitas Indonesia Library, Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Indonesia.
- [12] Fatati, I. F., Wijayanto, H., & Sholeh, A. M. (2017). Analisis regresi spasial dan pola penyebaran pada kasus demam berdarah dengue (DBD) di Provinsi Jawa Tengah. *Media Statistika*, 10(2), 95-105.
- [13] Yasin, H., Hakim, A. R., & Warsito, B. (2020). Regresi Spasial. *Pekalongan: WADE group*
- [14] Nahar, J., Hertini, E., & Supian, S. Robust Lagrange Multiplier (RLM) Test in Determining Spatial Regression Model. In *THE CONFERENCE IORA International Conference on Operations Research 2018* (p. 123)
- [15] Djuraidah, A., & Wigena, A. H. (2012). Regresi Spasial untuk Menentukan Faktorfaktor Kemiskinan di Provinsi Jawa Timur. *Statistika*, 12(1)
- [16] Sari, D. N. E., Hayati, M. N., & Wahyuningsih, S. (2021). Model Spasial Autoregressive Moving Average (SARMA) pada Data Jumlah Kejadian Demam Berdarah Dengue (DBD) di Provinsi Kalimantan Timur dan Tengah Tahun 2016. *Eksponensial*, 11(1), 57-64

LAMPIRAN *CODE*

〇〇〇

```
# Data untuk membuat peta
library(sf)
# https://geosai.my.id/download-shp-kabupaten-kota-indonesia/
maps <- st_read("D:/Materi Kuliah UI/Topik Khusus I - Analisis Data Spasial/Tugas Topik Khusus I - Analisis Data
Spasial/Sumatera_Utara_ADMIN_BPS.shp")
maps$Kabupaten <- gsub("Kota ", "", maps$Kabupaten)
maps <- maps[order(maps$Kabupaten), ]
class(maps)
library(ggplot2)
ggplot(maps) + geom_sf()

# Data Tingkat Pengangguran Terbuka
library(readxl)
df <- read_excel("D:/Materi Kuliah UI/Topik Khusus I - Analisis Data Spasial/Tugas Topik Khusus I - Analisis Data
Spasial/data_sumut.xlsx")
df <- data.frame(df)
colnames(df)[1] <- "kab_kota"
df <- df[-1, ] # Menghilangkan Sumatera Utara
df <- df[order(df$kab_kota), ]
df[, -1] <- lapply(df[, -1], as.numeric)
View(df)

# Preprocessing
# Periksa nama kabupaten/kota
maps <- maps[!maps$Kabupaten=="Danau Toba", ]
df$kab_kota==maps$Kabupaten
df[df$kab_kota=="Labuhan Batu", ]$kab_kota <- "Labuhanbatu"
df[df$kab_kota=="Labuhanbatu Utara", ]$kab_kota <- "Labuhanbatu Utara"
maps[maps$Kabupaten=="Labuhan Batu", ]$Kabupaten <- "Labuhanbatu"
maps[maps$Kabupaten=="Labuhan Batu Selatan", ]$Kabupaten <- "Labuhanbatu Selatan"
maps[maps$Kabupaten=="Labuhan Batu Utara", ]$Kabupaten <- "Labuhanbatu Utara"
maps[maps$Kabupaten=="Tanjung Balai", ]$Kabupaten <- "Tanjungbalai"
maps[maps$Kabupaten=="Pematang Siantar", ]$Kabupaten <- "Pematangsiantar"
maps[maps$Kabupaten=="Toba Samosir", ]$Kabupaten <- "Toba"
df <- df[order(df$kab_kota), ]
maps <- maps[order(maps$Kabupaten), ]
colnames(maps)[5] <- "kab_kota"
df$kab_kota==maps$kab_kota

# Merge data
library(dplyr)
df_merge_sp <- inner_join(maps, df, by = "kab_kota")
df_merge_sp <- as(df_merge_sp, "Spatial")

# Cari centroid koordinat
centroid <- st_centroid(maps)
coords <- st_coordinates(centroid)
# Cek centroid pada peta
ggplot(maps) + geom_sf(aes(fill = df$kab_kota), show.legend = FALSE) +
  geom_sf(data = centroid, col = "black")
# Save koordinat
library(sp)
df_sp <- SpatialPointsDataFrame(coords, df)

# Label plot
label <- c()
i <- 1
for(lab in df$kab_kota){
  if (length(strsplit(lab, " ")[1]) > 1 || nchar(lab)>4){
    # Extract first three-letter string
    first_three <- gsub("\\b(\\w{3})\\w*\\b", "\\1", lab)
    first_three <- gsub("\\s", "", first_three)
    label[i] <- first_three
  } else{
    label[i] <- df$kab_kota[i]
  }
  i <- i + 1
}
label
labels <- data.frame(label = label, long = coords[, 1], lat = coords[, 2])

# Statistika Deskriptif
summary(df[, c("TPT_2022", "PPM_2022", "DR_2022", "GR_2022", "RRLS_2022")])
df[df$TPT_2022==min(df$TPT_2022), ]
df[df$TPT_2022==max(df$TPT_2022), ]
```

○○○

```
# Tingkat Pengangguran Terbuka (TPT) Tahun 2022
# https://maczokni.github.io/crime_mapping_textbook/spatial-regression-models.html#fitting-an-interpreting-a-spatial-
error-model
library(tmap)
tm_shape(df_merge_sp) +
  tm_fill("TPT_2022", title = "TPT", style = "quantile", palette = "Reds") +
  tm_borders(alpha = 0.1) +
  tm_layout(main.title = "Tingkat Pengangguran Terbuka (TPT) \ndi Provinsi Sumatera Utara Tahun 2022",
            main.title.size = 0.7, legend.position = c("left", "top"),
            legend.outside = TRUE, legend.title.size = 0.8)

library(ggspatial)
df[order(df$TPT_2022), ]
p1 <- ggplot(maps) + geom_sf(aes(fill = df$TPT_2022)) +
  geom_text(data = labels, aes(x = long, y = lat, label = label), size = 4, color = "black") +
  scale_fill_gradient(name = "TPT", low = "lightblue", high = "darkblue") +
  ggtitle("Tingkat Pengangguran Terbuka (TPT) \ndi Provinsi Sumatera Utara Tahun 2022") +
  xlab("Longitude") + ylab("Latitude") +
  annotation_scale(location = "bl", width_hint = 0.4) +
  annotation_north_arrow(location = "bl", which_north = "true",
                        pad_x = unit(0.0, "in"), pad_y = unit(0.2, "in"),
                        style = north_arrow_fancy_orienteering) +
  theme(plot.title = element_text(size = 14, face = "bold"))
# https://bookdown.org/brianwood1/QDASS/simple-static-maps.html
p1

# Persentase Penduduk Miskin (PPM) Tahun 2022
p2 <- ggplot(maps) + geom_sf(aes(fill = df$PPM_2022)) +
  scale_fill_gradient(name = "PPM", low = "lightgreen", high = "darkgreen") +
  ggtitle("Persentase Penduduk Miskin (PPM) \ndi Provinsi Sumatera Utara Tahun 2022") +
  xlab("Longitude") + ylab("Latitude") +
  annotation_scale(location = "bl", width_hint = 0.4) +
  annotation_north_arrow(location = "bl", which_north = "true",
                        pad_x = unit(0.0, "in"), pad_y = unit(0.2, "in"),
                        style = north_arrow_fancy_orienteering) +
  theme(plot.title = element_text(size = 14, face = "bold"))
p2

# Dependency Ratio (DR) Tahun 2022
p3 <- ggplot(maps) + geom_sf(aes(fill = df$DR_2022)) +
  scale_fill_gradient(name = "DR", low = "yellow", high = "red") +
  ggtitle("Dependency Ratio (DR) \ndi Provinsi Sumatera Utara Tahun 2022") +
  xlab("Longitude") + ylab("Latitude") +
  annotation_scale(location = "bl", width_hint = 0.4) +
  annotation_north_arrow(location = "bl", which_north = "true",
                        pad_x = unit(0.0, "in"), pad_y = unit(0.2, "in"),
                        style = north_arrow_fancy_orienteering) +
  theme(plot.title = element_text(size = 14, face = "bold"))
p3

# Gini Rasio (GR) Tahun 2022
library(viridis)
p4 <- ggplot(maps) + geom_sf(aes(fill = df$GR_2022)) +
  scale_fill_viridis_c(option = "cividis", name = "GR", direction = -1) +
  ggtitle("Gini Rasio (GR) \ndi Provinsi Sumatera Utara Tahun 2022") +
  xlab("Longitude") + ylab("Latitude") +
  annotation_scale(location = "bl", width_hint = 0.4) +
  annotation_north_arrow(location = "bl", which_north = "true",
                        pad_x = unit(0.0, "in"), pad_y = unit(0.2, "in"),
                        style = north_arrow_fancy_orienteering) +
  theme(plot.title = element_text(size = 14, face = "bold"))
p4

# Rata-Rata Lama Sekolah (RRLS) Tahun 2022
p5 <- ggplot(maps) + geom_sf(aes(fill = df$RRLS_2022)) +
  scale_fill_viridis_c(option = "rocket", name = "RRLS", direction = -1) +
  ggtitle("Rata-Rata Lama Sekolah (RRLS) \ndi Provinsi Sumatera Utara Tahun 2022") +
  xlab("Longitude") + ylab("Latitude") +
  annotation_scale(location = "bl", width_hint = 0.4) +
  annotation_north_arrow(location = "bl", which_north = "true",
                        pad_x = unit(0.0, "in"), pad_y = unit(0.2, "in"),
                        style = north_arrow_fancy_orienteering) +
  theme(plot.title = element_text(size = 14, face = "bold"))
p5

# Gabungan Plot
library(ggpubr)
ggarrange(p2, p3, p4, p5, ncol = 2, nrow = 2)

# Plot Transformasi Variabel
df$log_TPT <- log(df$TPT_2022)
density_data1 <- data.frame(x = df$log_TPT, group = "Sebelum")
density_data2 <- data.frame(x = log(df$TPT_2022), group = "Sesudah")
# Combine the datasets
density_data <- rbind(density_data1, density_data2)
# Create the plot
ggplot(density_data, aes(x = x, fill = group)) +
  geom_density(alpha = 0.5) +
  scale_fill_manual(values = c("blue", "red")) +
  labs(title = "Perbandingan Densitas Sebelum dan Sesudah \nTransformasi Logaritma Natural",
       x = "Values", y = "Density") +
  theme_minimal()
```

○ ○ ○

```
# Regresi Linier
reg <- lm(log(TPT_2022) ~ PPM_2022 + DR_2022 + GR_2022 + RRLS_2022, data = df)
summary(reg)
# Log-Likelihood
logLik(reg)
# AIC
AIC(reg)

# Residual
df_merge_sp$res_reg <- residuals(reg)
df_merge_sp$fitted_reg <- fitted(reg)
df_merge_sp$sd_breaks <- scale(df_merge_sp$res_reg)[, 1]
# Because scale is made for matrices, we just need to get the first column using [, 1]
# this is equal to (df_merge_sp$res_reg - mean(df_merge_sp$res_reg))/sd(df_merge_sp$res_reg)
summary(df_merge_sp$sd_breaks)
my_breaks <- c(-14, -3, -2, -1, 1, 2, 3, 14)
library(tmap)
tm_shape(df_merge_sp) +
  tm_fill("sd_breaks", title = "Residual", style = "fixed", breaks = my_breaks, palette = "-RdBu") +
  tm_borders(alpha = 0.1) +
  tm_layout(main.title = "Residual", main.title.size = 0.7,
            legend.position = c("right", "bottom"), legend.title.size = 0.8,
            legend.outside = TRUE)

# Uji Asumsi
# Uji Multikolinearitas
library(car)
vif(reg)
cor(df[, -1])

# Uji Normalitas
qqnorm(reg$residuals, ylab = "Residuals", xlab = "Normal Scores")
qqline(reg$residuals)
shapiro.test(reg$residuals)
ks.test(reg$residuals, "pnorm")

# Uji Durbin Watson (Autocorrelation)
library(lmtest)
dwtest(log(TPT_2022) ~ PPM_2022 + DR_2022 + GR_2022 + RRLS_2022, data = df)

# Uji Heteroskedastisitas
bptest(reg)
spreadLevelPlot(reg)
par(mfrow = c(2, 2))
plot(reg)
par(mfrow = c(1, 1))
plot(reg, 1)

# Autokorelasi Spasial/Dependensi Spasial
library(spdep)
# Create a list of neighbours using the Queen criteria
w <- poly2nb(df_merge_sp, row.names = df_merge_sp$kab_kota) # sp object
summary(w)
# Generates a weights matrix for a neighbours list with spatial weights
wm <- nb2mat(w, style = 'B')
# Convert a square spatial weights matrix to a weights list object
rwm <- mat2listw(wm, style = 'W')

# Uji Indeks Moran
# Variabel Dependen
moran.test(log(df_merge_sp$TPT_2022), rwm, alternative = "two.sided")
# Variabel Independen
moran.test(df_merge_sp$PPM_2022, rwm, alternative = "two.sided")
moran.test(df_merge_sp$DR_2022, rwm, alternative = "two.sided")
moran.test(df_merge_sp$GR_2022, rwm, alternative = "two.sided")
moran.test(df_merge_sp$RRLS_2022, rwm, alternative = "two.sided")
# Residual
lm.morantest(reg, rwm, alternative = "two.sided")

# Lagrange Multipliers
lm.LMtests(reg, rwm, test = c("LMerr", "LMlag", "RLMerr", "RLMlag", "SARMA"))
```

○ ○ ○

```
# Spatial Regression
# https://rpubs.com/r_anisa/Spatial-Durbin
# https://r-spatial.org/book/17-Econometrics.html
# https://chrismgentry.github.io/Spatial-Regression/

# Spatial Lag Model (SLM)/Spatial Autoregressive (SAR) Model
library(spatialreg)
model <- "log(TPT_2022) ~ PPM_2022 + DR_2022 + GR_2022 + RRLS_2022"
sar <- lagsarlm(model, data = df_merge_sp, rwm)
summary(sar)
# Impact measures
W <- as(rwm, "CsparseMatrix")
trMC <- trW(W, type = "MC")
im <- impacts(sar, tr = trMC, R = 100)
sums <- summary(im, zstats = TRUE)
data.frame(sums$res)
# To print the p-values
data.frame(sums$pmat)
# Asumsi
ks.test(sar$residuals, "pnorm")
bptest.Sarlm(sar)
# Log-Likelihood
sar$LL
# AIC
AIC(sar)

# Spatial Error Model (SEM)
sem <- errorsarlm(model, data = df_merge_sp, rwm)
summary(sem)
# Asumsi
ks.test(sem$residuals, "pnorm")
bptest.Sarlm(sem)
# Log-Likelihood
sem$LL
# AIC
AIC(sem)

# Spatial Lag Exogeneous (SLX) Model
slx <- lmSLX(model, data = df_merge_sp, rwm, Durbin = TRUE)
summary(slx)
# Asumsi
ks.test(slx$residuals, "pnorm")
bptest(slx)
# Log-Likelihood
logLik(slx)
# AIC
AIC(slx)

# Spatial Durbin Model (SDM)
sdm <- lagsarlm(model, data = df_merge_sp, rwm, type = "mixed")
summary(sdm)
sdm <- lagsarlm(model, data = df_merge_sp, rwm, Durbin = TRUE)
summary(sdm)
# Asumsi
ks.test(sdm$residuals, "pnorm")
bptest.Sarlm(sdm)
# Log-Likelihood
sdm$LL
# AIC
AIC(sdm)

# Spatial Durbin Error Model (SDEM)
sdem <- errorsarlm(model, data = df_merge_sp, rwm, etype = "mixed")
summary(sdem)
sdem <- errorsarlm(model, data = df_merge_sp, rwm, Durbin = TRUE)
summary(sdem)
# Asumsi
ks.test(sdem$residuals, "pnorm")
bptest.Sarlm(sdem)
# Log-Likelihood
sdem$LL
# AIC
AIC(sdem)

# Kelejian-Purchar Model/Spatial Autoregressive Combined (SAC) Model
sac <- sacsarlm(model, data = df_merge_sp, rwm, Durbin = FALSE)
summary(sac)
# Asumsi
ks.test(sac$residuals, "pnorm")
bptest.Sarlm(sac)
# Log-Likelihood
sac$LL
# AIC
AIC(sac)

# General Nested Spatial Model (GNSM)
gnsml <- sacsarlm(model, data = df_merge_sp, rwm, Durbin = TRUE)
summary(gnsml)
# Asumsi
ks.test(gnsml$residuals, "pnorm")
bptest.Sarlm(gnsml)
# Log-Likelihood
gnsml$LL
# AIC
AIC(gnsml)
```

○ ○ ○

```
# Visualisasi Residual
# Regresi Linier (OLS)
r1 <- ggplot(maps) + geom_sf(aes(fill = reg$residuals)) +
  scale_fill_gradient2(name = "Residual", low = "red", mid = "white",
    high = "blue", midpoint = 0) +
  ggtitle("Residual Model Regresi Linier (OLS)") +
  xlab("Longitude") + ylab("Latitude") +
  annotation_scale(location = "bl", width_hint = 0.4) +
  annotation_north_arrow(location = "bl", which_north = "true",
    pad_x = unit(0.0, "in"), pad_y = unit(0.2, "in"),
    style = north_arrow_fancy_orienteering) +
  theme(plot.title = element_text(size = 10, face = "bold"))

# SAR
r2 <- ggplot(maps) + geom_sf(aes(fill = sar$residuals)) +
  scale_fill_gradient2(name = "Residual", low = "red", mid = "white",
    high = "blue", midpoint = 0) +
  ggtitle("Residual Model Spatial Autoregressive (SAR)") +
  xlab("Longitude") + ylab("Latitude") +
  annotation_scale(location = "bl", width_hint = 0.4) +
  annotation_north_arrow(location = "bl", which_north = "true",
    pad_x = unit(0.0, "in"), pad_y = unit(0.2, "in"),
    style = north_arrow_fancy_orienteering) +
  theme(plot.title = element_text(size = 10, face = "bold"))

# SEM
r3 <- ggplot(maps) + geom_sf(aes(fill = sem$residuals)) +
  scale_fill_gradient2(name = "Residual", low = "red", mid = "white",
    high = "blue", midpoint = 0) +
  ggtitle("Residual Spatial Error Model (SEM)") +
  xlab("Longitude") + ylab("Latitude") +
  annotation_scale(location = "bl", width_hint = 0.4) +
  annotation_north_arrow(location = "bl", which_north = "true",
    pad_x = unit(0.0, "in"), pad_y = unit(0.2, "in"),
    style = north_arrow_fancy_orienteering) +
  theme(plot.title = element_text(size = 10, face = "bold"))

# SLX
r4 <- ggplot(maps) + geom_sf(aes(fill = slx$residuals)) +
  scale_fill_gradient2(name = "Residual", low = "red", mid = "white",
    high = "blue", midpoint = 0) +
  ggtitle("Residual Model Spatial Lag Exogenous (SLX)") +
  xlab("Longitude") + ylab("Latitude") +
  annotation_scale(location = "bl", width_hint = 0.4) +
  annotation_north_arrow(location = "bl", which_north = "true",
    pad_x = unit(0.0, "in"), pad_y = unit(0.2, "in"),
    style = north_arrow_fancy_orienteering) +
  theme(plot.title = element_text(size = 10, face = "bold"))

# SDM
r5 <- ggplot(maps) + geom_sf(aes(fill = sdm$residuals)) +
  scale_fill_gradient2(name = "Residual", low = "red", mid = "white",
    high = "blue", midpoint = 0) +
  ggtitle("Residual Spatial Durbin Model (SDM)") +
  xlab("Longitude") + ylab("Latitude") +
  annotation_scale(location = "bl", width_hint = 0.4) +
  annotation_north_arrow(location = "bl", which_north = "true",
    pad_x = unit(0.0, "in"), pad_y = unit(0.2, "in"),
    style = north_arrow_fancy_orienteering) +
  theme(plot.title = element_text(size = 10, face = "bold"))

# SDEM
r6 <- ggplot(maps) + geom_sf(aes(fill = sdem$residuals)) +
  scale_fill_gradient2(name = "Residual", low = "red", mid = "white",
    high = "blue", midpoint = 0) +
  ggtitle("Residual Spatial Durbin Error Model (SDEM)") +
  xlab("Longitude") + ylab("Latitude") +
  annotation_scale(location = "bl", width_hint = 0.4) +
  annotation_north_arrow(location = "bl", which_north = "true",
    pad_x = unit(0.0, "in"), pad_y = unit(0.2, "in"),
    style = north_arrow_fancy_orienteering) +
  theme(plot.title = element_text(size = 10, face = "bold"))

# SAC
r7 <- ggplot(maps) + geom_sf(aes(fill = sac$residuals)) +
  scale_fill_gradient2(name = "Residual", low = "red", mid = "white",
    high = "blue", midpoint = 0) +
  ggtitle("Residual Model Spatial Autoregressive Combined (SAC)") +
  xlab("Longitude") + ylab("Latitude") +
  annotation_scale(location = "bl", width_hint = 0.4) +
  annotation_north_arrow(location = "bl", which_north = "true",
    pad_x = unit(0.0, "in"), pad_y = unit(0.2, "in"),
    style = north_arrow_fancy_orienteering) +
  theme(plot.title = element_text(size = 10, face = "bold"))

# GNSM
r8 <- ggplot(maps) + geom_sf(aes(fill = gns$residuals)) +
  scale_fill_gradient2(name = "Residual", low = "red", mid = "white",
    high = "blue", midpoint = 0) +
  ggtitle("Residual General Nested Spatial Model (GNSM)") +
  xlab("Longitude") + ylab("Latitude") +
  annotation_scale(location = "bl", width_hint = 0.4) +
  annotation_north_arrow(location = "bl", which_north = "true",
    pad_x = unit(0.0, "in"), pad_y = unit(0.2, "in"),
    style = north_arrow_fancy_orienteering) +
  theme(plot.title = element_text(size = 10, face = "bold"))

ggarrange(r1, r2, r3, r4, ncol = 2, nrow = 2)
ggarrange(r5, r6, r7, r8, ncol = 2, nrow = 2)

# Save Hasil
df$longitude <- coords[, 1]
df$latitude <- coords[, 2]
library("writexl")
tabel_data <- df[, c("kab_kota", "TPT_2022", "PPM_2022", "DR_2022", "GR_2022", "RRLS_2022",
  "longitude", "latitude")]
write_xlsx(tabel_data, "D:/Materi Kuliah UI/Topik Khusus I - Analisis Data Spasial/Tugas Topik Khusus I - Analisis Data
Spasial/tabel_data3.xlsx")
```


LAMPIRAN DATA

kab_kota	TPT_2022	PPM_2022	DR_2022	GR_2022	RRLS_2022	longitude	latitude
Asahan	6.26	8.64	42.75	0.255	8.82	99.56282855	2.802542074
Batu Bara	6.21	11.53	46.85	0.243	8.26	99.47563895	3.234237548
Binjai	6.36	5.1	42.32	0.302	11.18	98.48871083	3.599491152
Dairi	0.88	7.88	48.16	0.221	9.72	98.26731654	2.84362578
Deli Serdang	8.79	3.62	42.13	0.27	10.27	98.69435114	3.480842731
Gunungsitoli	3.65	14.81	46.19	0.303	8.64	97.58309154	1.265094099
Humbang Hasundutan	0.42	8.86	50.82	0.258	10	98.5724341	2.270728046
Karo	2.71	8.17	42.43	0.236	10.02	98.29604788	3.120686547
Labuhanbatu	6.9	8.26	42.2	0.278	9.4	100.0564698	2.279357048
Labuhanbatu Selatan	3.15	8.09	42.4	0.247	8.92	100.1305356	1.83886421
Labuhanbatu Utara	3.75	9.09	43.14	0.276	8.64	99.7546035	2.409090453
Langkat	6.88	9.49	43.65	0.26	8.68	98.22034671	3.710688448
Mandailing Natal	7.64	8.92	49.27	0.244	8.76	99.36944505	0.77436529
Medan	8.89	8.07	39.51	0.399	11.5	98.66799658	3.627720856
Nias	2.81	16	49.93	0.275	5.88	97.72837854	1.065937681
Nias Barat	0.53	24.75	45.07	0.21	6.97	97.4896517	1.025365843
Nias Selatan	3.69	16.48	35.18	0.223	6.23	98.10363891	0.32041484
Nias Utara	2.59	23.4	41.27	0.239	6.78	97.35547868	1.312779528
Padang Lawas	5.9	8.05	46.57	0.227	9.31	99.84412445	1.140399419
Padang Lawas Utara	4.31	8.94	46.9	0.245	9.46	99.75745406	1.59325322
Padangsidempuan	7.76	6.89	43.06	0.275	11.11	99.28079543	1.396311455
Pakpak Bharat	0.26	8.66	49.85	0.274	9.39	98.24060676	2.55417163
Pematangsiantar	9.36	7.88	41.68	0.321	11.31	99.0589741	2.962597604
Samosir	1.16	11.77	52.46	0.298	9.46	98.72129157	2.558723482
Serdang Bedagai	4.98	7.82	44.51	0.24	8.71	99.05853505	3.367155536
Sibolga	7.05	11.47	42.49	0.346	10.43	98.78590557	1.738364364
Simalungun	5.51	8.26	40.62	0.262	9.63	99.03322489	2.977031356
Tanjungbalai	4.62	12.45	44.18	0.245	9.55	99.79498813	2.964415352
Tapanuli Selatan	3.65	8.07	48.33	0.209	9.34	99.25804545	1.492726215
Tapanuli Tengah	7.97	11.71	43.13	0.233	8.86	98.65979448	1.833887203
Tapanuli Utara	1.07	8.93	52.18	0.242	10	99.06974134	1.989761642
Tebing Tinggi	6.39	9.59	42.08	0.334	10.65	99.15570836	3.328360051
Toba	1.39	8.89	48.93	0.305	10.58	99.2642168	2.379730791

KONTRIBUSI KELOMPOK

No.	Nama	NPM	Kontribusi	Tingkat Kontribusi
1.	Daniella Putri Shalomita	2106631072	Menyusun makalah dan poster	100%
2.	Diki Wahyudi	2106709131	Melakukan pengolahan dan analisis data	100%
3.	Raqi Akbar Robbani	2106652562	Menyusun makalah dan poster	100%